BÁO CÁO FINAL • TEXT-TO-SQL

Texa

Hỏi dữ liệu thương mại điện tử bằng ngôn ngữ tự nhiên

Phạm vi rõ ràng • Cách tính có thể kiểm tra • Kết quả có thể đối chứng

Một câu hỏi cần một căn cứ rõ ràng

CÂU HỎI CỦA PM/PO

“Doanh thu tháng trước là bao nhiêu?”

01

METRIC NÀO?

Doanh thu được định nghĩa ra sao?

Theo semantic catalog

02

NGUỒN NÀO?

Cosmetics hay Olist?

Theo source contract

03

KỲ NÀO?

Khoảng thời gian và filter nào?

Theo QuerySpec đã kiểm tra

Texa trả kết quả kèm căn cứ: metric • nguồn • kỳ • filter • SQL

Phạm vi thực hiện

01 NGƯỜI DÙNG

PM/PO và quản lý e-commerce

Hỏi nhanh, truy vấn gọn, kiểm tra được

02 DOMAIN & ENGINE

Event e-commerce / PostgreSQL

Mỗi truy vấn dùng một nguồn

03 METRIC

8 metric gốc trong semantic catalog

Thời gian, filter, breakdown, top-k hợp lệ

04 NESTED CÓ GIỚI HẠN

Scalar khai báo trước, tối đa 2 key

Ví dụ: ep.device.type

Mục tiêu: mỗi câu trả lời đều truy ngược được về metric, nguồn và kỳ báo cáo.

Scope nhỏ để kiểm soát chất lượng và giải thích được kết quả.

Tám metric gốc, nhiều cách kết hợp

Mỗi metric có định nghĩa, nguồn dữ liệu và cách kiểm tra riêng.

Events
Số sự kiện

Users
Người dùng duy nhất

Sessions
Phiên duy nhất

Viewers
Người xem duy nhất

Buyers
Người mua duy nhất

Purchases
Event mua item

Revenue
Theo tiền tệ nguồn

Buyer conversion
Buyers / observed users

8 metric gốc × thời gian × filter × breakdown = nhiều truy vấn và insight hợp lệ.

Catalog còn quản lý dimensions, event roles và mapping; không phải mỗi dòng trong catalog là một metric.

Vì sao chọn Cosmetics và Olist?

Hai nguồn cùng domain nhưng khác góc nhìn dữ liệu; bổ sung cho nhau để kiểm tra semantic layer.

HÀNH VI NGƯỜI DÙNG

Cosmetics • USD

- Luồng sự kiện xem → giỏ → mua.
- Có product views và sessions.
- Kiểm thử chỉ số về người dùng và hành vi.
- Không có dữ liệu giao hàng / đánh giá.

BỐI CẢNH GIAO DỊCH

Olist • BRL

- Dữ liệu quan hệ: đơn, item và lifecycle.
- Purchase được biểu diễn theo từng item.
- Kiểm thử ánh xạ event và phân biệt item / order.
- Không ghi nhận product views / sessions.

VÌ SAO CHỌN CẢ HAI?

Cosmetics kiểm tra hành vi trước mua; Olist kiểm tra giao dịch và vòng đời đơn.
Hai nguồn khác nhau nhưng bổ sung cho nhau: một bên thử funnel/event, một bên thử item/order/lifecycle.

ELT: từ dữ liệu nguồn đến semantic layer

Giữ dữ liệu gốc, chuẩn hóa trong PostgreSQL, rồi gắn định nghĩa nghiệp vụ.

01 · EXTRACT

Dữ liệu nguồn

Cosmetics / Olist
CSV và records gốc

▶

02 · LOAD

Nạp vào PostgreSQL

Giữ bản ghi gốc
theo từng nguồn

▶

03 · TRANSFORM

Chuẩn hóa event

Kiểu dữ liệu, ngày, field
và event role

▶

04 · SEMANTIC LAYER

Event mart + catalog

Metric, mapping, coverage
sẵn sàng cho Texa

Khó khăn khi mapping: Olist là vòng đời đơn, Cosmetics là luồng hành vi nên user_id, giờ, purchase và revenue khác nghĩa (Olist: không có session, giờ Brazil lưu như UTC, purchases/revenue gồm cả đơn hủy). Đã thêm ghi chú theo nguồn hiện cùng kết quả và 2 quality check ở bước ETL.

Kết quả của ELT: một lớp event thống nhất, nhưng vẫn giữ ngữ nghĩa riêng của từng nguồn.

Texa dùng event mart và semantic catalog để xác định metric, nguồn và cách tính trước khi sinh QuerySpec.

Kiến trúc triển khai: từ câu hỏi đến kết quả kiểm chứng được

LLM đề xuất cách hiểu; catalog, compiler và lớp kiểm tra quyết định truy vấn nào được phép chạy.

LLM CALL | CODE / DỮ LIỆU

01 · CÂU HỎI + MEMORY

Ngữ cảnh đầu vào

Câu hỏi mới + slot và kết quả đã xác nhận

→

02 · RETRIEVAL

Ví dụ phù hợp

Verified examples + catalog entries liên quan

→

03 · LLM HIỂU Ý

Candidate có cấu trúc

Gọi model → intent, metric, source, filters

→

04 · CONSISTENCY

Kiểm tra khi cần

Hai mẫu LLM song song → chọn cách hiểu ổn định

05 · BIND + VALIDATE

QuerySpec hợp lệ

Catalog kiểm tra metric, source, time, filter, breakdown và coverage. Thiếu hoặc mơ hồ → hỏi lại.

→

06 · COMPILE + CHECK

SQL được kiểm soát

Compiler → SQL tham số hóa. sqlglot AST + sandbox read-only kiểm tra và tự sửa trong giới hạn.

→

07 · THỰC THI + TRẢ KẾT QUẢ

Facts có nguồn

PostgreSQL read-only → bảng + SQL. LLM chỉ diễn giải facts đã kiểm chứng và gắn trích dẫn cho nhận xét.

Mọi bước sau LLM đều được kiểm tra bằng semantic catalog, code và dữ liệu read-only.

Ví dụ về một câu hỏi đi qua hệ thống

“Doanh thu theo danh mục của Cosmetics tháng 12/2019.”

RETRIEVAL → INTENT → QUERYSPEC

source: cosmetics_shop

metric: revenue

breakdown: item_category

period: 2019-12-01 … 2019-12-31

SQL có tham số → PostgreSQL chỉ đọc

→

KẾT QUẢ WAREHOUSE • TOP 3

Danh mục	Revenue (USD)
(chưa có danh mục)	**1.037.866,82**
appliances	**22.964,12**
furniture	**7.300,22**

Bảng đầy đủ vẫn gồm các nhóm còn lại.

Phạm vi: Cosmetics • revenue • item_category • 01–31/12/2019
Bảng minh họa top 3 nhóm theo doanh thu; NULL là nhóm chưa có danh mục, không được tự loại bỏ.
Nguồn: SQL đối chiếu warehouse đã lưu, ngày 05/11/2026.

Các lớp kiểm tra để bảo đảm câu trả lời có căn cứ

Bước	Hành vi	Ý nghĩa
Thiếu thông tin	Hỏi lại nguồn / kỳ / metric	Không tự đoán phần chưa rõ
Ngoài phạm vi	Báo metric / field không hỗ trợ	Thiếu dữ liệu không phải số 0
Trước thực thi	Validate QuerySpec + coverage	Chỉ dùng định nghĩa hợp lệ
Trong thực thi	SQL có tham số; read-only	Timeout và giới hạn dòng
Sau thực thi	Server tính facts; LLM tham chiếu	Con số có thể đối chứng

SQL chạy được chưa đủ; Texa còn phải kiểm tra cách hiểu, phạm vi dữ liệu và căn cứ của kết quả.

Structured memory cho hỏi tiếp

Lượt hỏi	Thông tin được giữ / đổi	Trách nhiệm của hệ thống
Doanh thu Cosmetics tháng 12/2019?	Nguồn + metric + kỳ	Lưu truy vấn thành công
Chia theo danh mục.	Giữ nguồn, metric, kỳ Đổi breakdown	Chọn ngữ cảnh phù hợp
Chỉ giữ accessories.	Giữ phần đã xác lập Thêm filter	Không để câu xã giao ghi đè
Bạn đang nhắc kết quả nào?	Tham chiếu chưa rõ	Hỏi lại; kiểm tra snapshot/catalog

Thiết kế thay cửa sổ cố định bằng state có cấu trúc. Một số tham chiếu tiếng Việt vẫn còn lỗi; kết quả ở phần (cấu hình so sánh) phía sau.

Catalog thay đổi: quy trình và tác động

Catalog là hợp đồng semantic; thay đổi phải được kiểm tra và phát hành theo version.

1. QUY TRÌNH THAY ĐỔI

① Sửa metric, dimension hoặc mapping trong YAML.

② Validate cấu trúc, cross-reference và coverage với source.

③ Publish thành một catalog version mới vào database.

④ Câu hỏi mới dùng version mới; không sửa ngầm version cũ.

2. KHI CATALOG / SCHEMA ĐỔI

• Phiên bản đang chạy: giữ catalog version đã đọc lúc bắt đầu, không đổi nghĩa giữa chừng.

• Schema hoặc source đổi: coverage/validation kiểm tra lại; thiếu field hoặc metric thì không cho chạy.

• Hội thoại / QuerySpec cũ: nếu khác version, không tự kế thừa; yêu cầu người dùng hỏi lại theo version mới.

Mục tiêu: không để một thay đổi định nghĩa làm kết quả cũ bị đổi nghĩa âm thầm.

Đánh giá: baseline, Texa và bộ benchmark

Cùng model, câu hỏi, fixture và cách chấm; khác ở thông tin và workflow được phép dùng.

BASELINE — LLM SINH SQL TRỰC TIẾP

Cùng gpt-6-luna
Nhận: câu hỏi + schema PostgreSQL + source
Không nhận: catalog, định nghĩa nghiệp vụ, examples
→ Sinh SQL → thực thi

TEXA ĐẦY ĐỦ

Cùng gpt-6-luna
Nhận thêm: semantic catalog + memory
Retrieval + consistency khi cần
→ QuerySpec → compiler → validation → thực thi

BỘ BENCHMARK DÙNG CHUNG

300 câu đơn (100 dev / 200 test) • 60 clarification • 40 hội thoại • 40 ngoài scope

Cosmetics + Olist • fixture cố định • chấm bảng kết quả so với gold • mỗi cấu hình chạy 2 lần

Giới hạn: còn template overlap, chưa có holdout độc lập; kết quả exploratory, không suy ra production accuracy.

Bổ sung sau góp ý: 22,5% của baseline chủ yếu đo việc thiếu định nghĩa nghiệp vụ, nên thêm thang baseline schema → + ví dụ → + định nghĩa Texa (B0G) → + sửa SQL (B0GR) → Texa; số liệu mới: chờ chạy. Bộ test v4 dùng dữ liệu thật, 300 câu, đáp án tính độc lập từ CSV.

QUY TẮC ĐÁNH GIÁ

Đánh giá câu trả lời dựa trên bảng kết quả, không dựa trên chuỗi SQL.

1. QUY TẮC ĐÁNH GIÁ

• SQL khác nhau vẫn được tính đúng nếu bảng kết quả khớp gold.

• Chạy trên cùng fixture/snapshot; so toàn bộ bảng.

• Khớp cột, dòng, NULL và duplicate; thứ tự dòng chỉ quan trọng khi đề bài yêu cầu.

• Sai số số học cho phép 1e-6; lỗi hoặc timeout vẫn tính là sai; tên cột (alias) không cần giống.

2. METRIC ĐÁNH GIÁ

• Business accuracy: tỷ lệ bảng kết quả đúng trên toàn bộ câu hỏi.

• Clarification: bảng cuối đúng và hệ thống hỏi lại đúng lúc.

• Hội thoại: độ đúng của từng answer slot, action và tham chiếu.

• Đo bổ sung: thời gian, số lần gọi model và token.

QuerySpec hoặc JSON đúng chưa đủ: kết quả cuối cùng mới là căn cứ chấm chính.

Độ chính xác của đáp án chuẩn (bộ v4): tính độc lập từ CSV thật bằng DuckDB; 300 câu, 96 nhóm dạng câu, dev/test không trùng nhóm; 300/300 SQL chuẩn khớp. Chưa có review người nên vẫn là exploratory.

Kết quả benchmark — câu hỏi đơn

200 câu test × 2 lần chạy · Business accuracy theo bảng kết quả

Phiên bản	Đúng / 400 lượt	Tỷ lệ
LLM baseline · schema-only	90	22,50%
Texa without retrieval and consistency	350	87,50%
Texa with only consistency	348	87,00%
Texa with only retrieval	361	90,25%
Texa	**365**	**91,25%**

Texa vượt baseline rõ rệt; retrieval đóng góp tích cực, còn consistency chưa cho thấy lợi ích ổn định. Kết quả vẫn là exploratory.

Kết quả theo loại tác vụ

Hội thoại, clarification và ngoài scope được chấm riêng

Phiên bản	Hội thoại[1]	Hỏi lại[2]	Ngoài scope[3]
LLM baseline · có history	14,77%	67,50%	5,00%
Texa without retrieval and consistency	91,40%	100%	83,75%
Texa with only consistency	92,05%	100%	93,75%
Texa with only retrieval	**96,10%**	99,17%	86,25%
Texa	**94,81%**	**100%**	**95,00%**

[1] Bảng đúng: 308 lượt có đáp án × 2 lần chạy; 40 hội thoại, tổng 355 lượt mỗi lần.
[2] Hành động hỏi lại đúng: 60 tình huống × 2. [3] Hành động xử lý đúng: 40 câu × 2.

Cách đọc: mỗi cột đo một năng lực khác nhau; không gộp thành một accuracy chung.

Ablation — retrieval và consistency

Chỉ thay retrieval và consistency; giữ các thành phần còn lại

Phiên bản Texa	Câu đơn	Hội thoại
Texa without retrieval and consistency	87,50%	91,40%
Texa with only consistency	87,00%	92,05%
Texa with only retrieval	90,25%	96,10%
Texa	**91,25%**	**94,81%**

- Retrieval giúp ích rõ hơn ở bộ câu hỏi và hội thoại này.
- Consistency không cải thiện ổn định ở mọi loại tác vụ; cần đọc theo từng suite.

Không có một component đơn lẻ nào thắng ở mọi loại tác vụ.

Ablation — memory và clarification

Giữ retrieval và consistency; thay từng thành phần một

Phiên bản	Hội thoại	Clarification	Hỏi lại đúng
Texa with structured memory	84,58% 521/616	—	—
Texa with only window-6 memory	85,55% 527/616	—	—
Texa without memory	83,93% 517/616	—	—
Texa with clarification	—	86,67% 104/120	75,00%
Texa without clarification	**—**	**62,50%** **75/120**	**50,00%**

- Memory có ảnh hưởng nhỏ và chưa đủ để kết luận cấu hình nào ổn định hơn.
- Clarification tạo khác biệt rõ hơn vì giúp hệ thống không đoán khi thiếu thông tin.

Kết quả dùng để chẩn đoán thành phần, không phải bằng chứng tổng quát cho mọi hệ thống.

Kết luận

Ba insight chính rút ra từ thiết kế và kết quả đánh giá

01

SEMANTIC LAYER CÓ GIÁ TRỊ

- Định nghĩa metric và mapping giúp Texa hiểu yêu cầu theo một căn cứ thống nhất.
- QuerySpec, compiler và validation giúp kết quả có thể kiểm tra.

02

HỎI LẠI QUAN TRỌNG HƠN ĐOÁN

- Clarification giúp hệ thống xử lý an toàn khi câu hỏi thiếu hoặc mơ hồ.
- Memory có cấu trúc phù hợp hơn việc chỉ giữ một cửa sổ hội thoại cố định.

03

HIỆU QUẢ PHỤ THUỘC TÁC VỤ

- Retrieval và consistency không phải lúc nào cũng cùng tăng chất lượng.
- Cần tiếp tục review gold độc lập và khóa holdout trước khi mở rộng phạm vi.

Texa là trợ lý phân tích có căn cứ trong một phạm vi được kiểm soát.

Kết quả có thể đối chứng; không cam kết đúng tuyệt đối.