# Texa

## Trợ lý phân tích thương mại điện tử dựa trên Semantic Layer và Text-to-SQL có kiểm soát

**Nhóm thực hiện Texa**

Tháng 11 năm 2026

Tóm tắt. Texa là trợ lý hỏi–đáp dữ liệu cho PM, PO và cấp quản lý, dùng semantic catalog, QuerySpec và compiler để tạo truy vấn có thể kiểm tra. Trên 200 câu test research-v3, chạy hai lần cùng model gpt-6-luna, Baseline (schema + định nghĩa nghiệp vụ + một lần sửa SQL khi lỗi) đạt 89,00% (356/400); Texa đạt 91,25% (365/400), chênh 2,25 điểm phần trăm. Các phép đo hội thoại, hỏi lại và ngoài phạm vi được báo cáo riêng cho các cấu hình Texa; chưa có đối chiếu baseline ở những suite này. Đây là kết quả thăm dò trong phạm vi đã chọn.

**Từ khóa:** Text-to-SQL · semantic layer · QuerySpec · schema linking · structured memory · clarification · PostgreSQL · e-commerce analytics

# Mục lục

1. Giới thiệu
2. Bài toán, người dùng và phạm vi
3. Tổng quan nghiên cứu liên quan
4. Yêu cầu và nguyên tắc thiết kế
5. Kiến trúc và workflow của Texa
6. Dữ liệu và semantic catalog
7. Thiết kế benchmark và metric
8. Kết quả thực nghiệm
9. Thảo luận và giới hạn
10. Kết luận và hướng phát triển

Phụ lục: Tái lập và thuật ngữ

Tài liệu tham khảo

# 1. Giới thiệu

## 1.1. Bối cảnh

Các nhóm kinh doanh thường cần trả lời những câu hỏi như “doanh thu tháng trước là bao nhiêu?”, “nhóm sản phẩm nào có nhiều người mua nhất?” hoặc “kết quả vừa rồi nếu chỉ xem nhóm phụ kiện thì thế nào?”. Những câu hỏi này chứa nhiều quyết định ngầm: doanh thu tính trên event nào, nguồn nào được dùng, kỳ thời gian ra sao, có group theo danh mục hay không và hệ thống có đủ dữ liệu để trả lời hay không.

Một LLM có thể sinh SQL trực tiếp từ câu hỏi và schema, nhưng cách này buộc mô hình tự khôi phục định nghĩa nghiệp vụ từ tên bảng/cột. Khi schema có nhiều event, nhiều nguồn và trường nested, một truy vấn chạy được vẫn có thể sai về metric hoặc grain. Đây là khoảng trống Texa tập trung giải quyết.

## 1.2. Vấn đề cần giải quyết

Bài toán của Texa là chuyển câu hỏi phân tích tự nhiên thành kết quả có thể kiểm tra theo bốn câu hỏi: hệ thống đang đo metric nào, lấy từ nguồn nào, trên kỳ và bộ lọc nào, và vì sao truy vấn được phép chạy. Độ chính xác tuyệt đối không được giả định; kết quả phải nằm trong catalog và scope đã công bố.

## 1.3. Đóng góp

1. Semantic catalog cho metric, dimension, event role, coverage và mapping giữa hai nguồn có schema khác nhau.
2. Pipeline tách rõ intent, retrieval ví dụ đã xác minh, consistency chọn lọc, binder/clarification, QuerySpec, compiler, validation và execution.
3. Structured memory lưu slot ngữ nghĩa và ID kết quả thay vì chỉ lấy sáu lượt chat gần nhất.
4. Benchmark nhiều loại tác vụ và ablation để đo câu đơn, hỏi lại, hội thoại, ngoài scope, retrieval, consistency, memory và clarification.

# 2. Bài toán, người dùng và phạm vi

## 2.1. Đối tượng sử dụng

Texa được định hướng cho PM, PO và cấp quản lý cần kiểm tra xu hướng, so sánh nhóm và theo dõi chỉ số mà không có chuyên môn SQL sâu. Hệ thống hỗ trợ ra quyết định sơ bộ; không thay thế review nghiệp vụ, BI chính thức hoặc phân tích nhân quả.

## 2.2. Phạm vi thực hiện

| | |
|---|---|
| **Domain**<br>Event commerce | **Engine**<br>PostgreSQL |
| **Nguồn**<br>Cosmetics Shop và Olist; mỗi truy vấn chỉ dùng một nguồn | **Nested**<br>Scalar path được catalog khai báo, sâu tối đa hai key; không bung array |

Hệ thống hỗ trợ tám metric gốc: **Events, Users, Sessions, Viewers, Purchases, Buyers, Revenue** và **Buyer conversion rate**. Đây không phải tám câu hỏi cố định: mỗi metric có thể kết hợp kỳ, filter, breakdown và top-k trong capability đã khai báo.

### 2.3. Giới hạn

Texa không tuyên bố chuẩn hóa mọi database của mọi công ty. Ngoài scope gồm delivery/review, order/AOV, retention, FX, causal claims, truy vấn tự do và truy vấn kết hợp hai nguồn. Khi field/event không có trong coverage, hệ thống phải báo unavailable hoặc hỏi lại; không biến dữ liệu thiếu thành số 0.

## 3. Tổng quan nghiên cứu liên quan

### 3.1. Schema linking và độ khó Text-to-SQL

Spider cho thấy Text-to-SQL khó khi schema đa dạng và câu hỏi yêu cầu suy luận compositional xuyên domain. RAT-SQL nhấn mạnh mã hóa quan hệ giữa câu hỏi và schema thay vì chỉ so khớp tên. BIRD đưa thêm thách thức về nội dung database và kiến thức nghiệp vụ; Spider 2.0 mở rộng sang workflow enterprise và thao tác nhiều bước.

**Texa kế thừa:** đưa quan hệ metric–event role–dimension vào catalog và thu hẹp scope. Binder chỉ cho phép combination đã được catalog xác nhận thay vì kỳ vọng LLM tự suy luận mọi quan hệ raw schema.

### 3.2. Decomposition, few-shot và self-correction

DIN-SQL phân rã Text-to-SQL thành các bước và dùng self-correction. DAIL-SQL nghiên cứu cách chọn và tổ chức demonstrations cho in-context learning. Texa kế thừa việc tách bước và dùng ví dụ liên quan; LLM xuất intent/QuerySpec có cấu trúc, còn compiler sinh SQL từ các phần tử đã được kiểm soát.

### 3.3. Constrained decoding và kiểm tra thực thi

PICARD cho thấy ràng buộc sinh token bằng parser có thể giảm SQL không hợp lệ. SQL-PaLM kết hợp nhiều candidate với execution-error filtering. Texa áp dụng nguyên lý này ở pipeline: AST check bằng sqlglot, capability/contract check, sandbox read-only và self-correction có giới hạn. SQL chạy được vẫn chưa đủ; kết quả phải đúng metric và grain.

### 3.4. Consistency và hội thoại

Self-consistency chọn đáp án từ nhiều đường suy luận. Texa chỉ bật consistency khi uncertainty hoặc xung đột cao, vote trên intent/QuerySpec để kiểm soát cost. SParC và CoSQL cho thấy hội thoại cần context và reference resolution. Texa dùng structured memory của QuerySpec/result registry và clarification, thay vì xem sáu message gần nhất là bộ nhớ duy nhất.

### 3.5. Semantic layer và governance

Các semantic layer thực tế quản lý metric, dimension, entity và quy tắc join ở một lớp dùng chung. Texa áp dụng mô hình này ở quy mô nhỏ: catalog là contract giữa ngôn ngữ người dùng và dữ liệu vật lý, có version, coverage và trạng thái review. Đây là tham khảo kiến trúc sản phẩm, không phải bằng chứng accuracy.

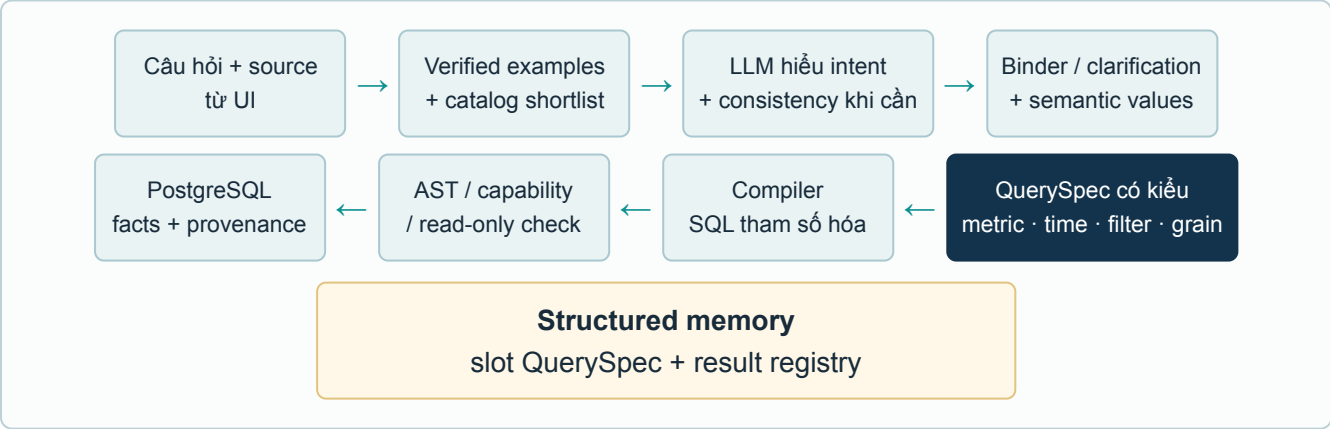
| Vấn đề | Bài học | Cách Texa xử lý |
|---|---|---|
| Raw schema linking | Tên cột không đủ để khôi phục ngữ nghĩa | Catalog khai báo metric, role, dimension, mapping và coverage |
| SQL invalid | Cần parser/validator trước execution | QuerySpec có kiểu, compiler, AST check và sandbox |
| SQL chạy được nhưng sai nghiệp vụ | Execution accuracy đơn thuần chưa đủ | Gold table theo metric/grain và business contract |
| Few-shot/consistency | Ví dụ liên quan và nhiều candidate có thể giúp | Verified example retrieval và adaptive consistency, đo cost riêng |
| Hội thoại | Reference resolution cần trạng thái có cấu trúc | Memory lưu slot + result ID; clarification khi mơ hồ |

# 4. Yêu cầu và nguyên tắc thiết kế

1. **Có căn cứ:** mọi câu trả lời truy nguyên được metric, source, time range, filter, breakdown và SQL.
2. **Có giới hạn:** chỉ cho phép capability mà catalog và source coverage xác nhận.
3. **Hỏi lại khi thiếu thông tin:** không đoán nguồn, kỳ, metric hoặc target tham chiếu mơ hồ.
4. **Tách intent khỏi SQL:** LLM hiểu ngôn ngữ; compiler tạo SQL.
5. **Đánh giá theo kết quả:** so sánh bảng kết quả với gold, không so chuỗi SQL.
6. **Có thể tái lập:** protocol, dataset, variant, repeat và raw trace được lưu lại.

# 5. Kiến trúc và workflow của Texa

## 5.1. Kiến trúc tổng thể




ETL đưa các nguồn về event rows với adapter tương ứng; semantic catalog giữ quy tắc diễn giải. Runtime nhận câu hỏi và source từ UI, rồi đi qua các lớp hiểu, kiểm tra và thực thi.

## 5.2. Semantic catalog

Catalog chứa metric definition và aggregation recipe; event role, event name và mapping field vật lý; dimensions, nested paths, source coverage và supported combinations; vocabulary business label sang raw value theo source; verified examples và metadata review/version.

Tám metric gốc tạo được nhiều truy vấn vì kết hợp với kỳ, filter và breakdown. “Revenue theo item category trong tháng trước” và “Top 3 category theo Revenue” dùng cùng metric nhưng khác shape và selection. Vì vậy số metric không phải số câu hỏi sản phẩm có thể nhận.

### 5.3. Intent, retrieval và consistency

LLM xuất candidate có cấu trúc gồm outcome, metric, source, time range, filters, dimensions và grain. Verified example retrieval cung cấp pattern đã review theo source và family. Consistency được bật có điều kiện khi uncertainty hoặc xung đột cao, sau đó candidate vẫn phải qua semantic checks.

### 5.4. Binder, QuerySpec và compiler

Binder resolve metric ID, source coverage, business value, date range và dimensions. Nếu thiếu thông tin bắt buộc, hệ thống clarification thay vì đoán. QuerySpec là intermediate representation có kiểu; compiler Python sinh SQL tham số hóa từ recipe đăng ký. LLM không tự viết SQL trong pipeline sản phẩm.

### 5.5. Validation, execution và provenance

SQL được kiểm tra AST, capability và read-only policy; candidate lỗi có thể được sửa trong giới hạn rồi kiểm tra lại. PostgreSQL reader trả facts cùng provenance để phần trả lời hiển thị metric, source, kỳ và cách tính. SQL hợp lệ nhưng sai event role hoặc grain vẫn bị loại bởi semantic contract.

### 5.6. Structured memory

Memory lưu slot QuerySpec và result registry, ví dụ ID bảng vừa trả về, metric, source, time range và breakdown. Follow-up như “còn nhóm phụ kiện thì sao?” được resolve vào result/slot đã tồn tại. Khi catalog hoặc snapshot không còn phù hợp, hệ thống hỏi lại hoặc yêu cầu chạy lại. Window-6 chỉ là một ablation, không phải thiết kế mặc định.

## 6. Dữ liệu và semantic catalog

### 6.1. Hai nguồn bổ sung cho nhau

Cosmetics Shop có event phong phú như product view, session và device/category, phù hợp kiểm tra funnel quan sát và nested attributes. Olist có item/order/purchase và thông tin marketplace, phù hợp kiểm tra revenue/purchase/buyer trên schema nghiệp vụ khác. Hai nguồn đủ khác nhau để kiểm tra mapping và coverage; chúng không bị join với nhau.

### 6.2. ETL đến semantic layer

Quy trình gồm bốn bước: **Extract** từ fixture/source adapter; **Load** vào PostgreSQL theo event contract; **Transform** chuẩn hóa event date, role và nested scalar; **Publish** semantic catalog cùng coverage. Thay đổi catalog phải sửa definition, validate schema/coverage, tăng version và publish atomically. Runtime đang chạy giữ version cũ; request mới dùng version mới và yêu cầu xác nhận lại nếu QuerySpec cũ không còn hợp lệ.

## 7. Thiết kế benchmark và metric

### 7.1. So sánh baseline

Trong phép so sánh câu đơn, Baseline và Texa dùng cùng model gpt-6-luna, fixture và 200 câu test, mỗi câu chạy hai lần. Baseline nhận câu hỏi, schema PostgreSQL và đúng các định nghĩa nghiệp vụ Texa nhận; nếu truy vấn lỗi khi thực thi, LLM được yêu cầu sửa một lần. Baseline không có QuerySpec, binder, compiler hay kiểm tra ngữ nghĩa của Texa. Các suite hội thoại, hỏi lại và ngoài phạm vi chưa có baseline đối chứng.

### 7.2. Bộ test

- 300 câu đơn: 100 dev và 200 test; test gồm 40 basic, 100 compositional và 60 semantic; cân bằng 100 Cosmetics/100 Olist, 140 tiếng Việt/60 tiếng Anh.

- 60 trường hợp clarification: 30 mơ hồ và 30 câu rõ ràng đối chứng, chạy hai lần.
- 40 hội thoại dài 6–12 lượt, tổng 355 lượt; 308 answer slots có gold table.
- 40 câu ngoài scope, chấm hành động xử lý đúng riêng với SQL accuracy.
- Gold gồm Python oracle và SQL; 2.004 kiểm tra SQL/world đã qua trước khi chạy model.

Hai repeat giúp quan sát dao động model nhưng không tăng gấp đôi số câu độc lập. Dataset tổng hợp có family compositional, semantic, nested và coverage counterexample; chưa phải sealed holdout được người độc lập adjudicate.

### 7.3. Metric

Business accuracy là tỷ lệ bảng kết quả khớp toàn bộ với gold: đúng cột theo vai trò/thứ tự và đúng toàn bộ hàng/giá trị; alias SQL khác nhau được chấp nhận. Truy vấn sai, từ chối sai, timeout hoặc không có kết quả khi gold có kết quả đều tính sai. Clarification có policy accuracy và final-table accuracy. Ngoài scope chấm hành động đúng. Latency và cost báo riêng, không cộng vào accuracy.

## 8. Kết quả thực nghiệm

### 8.1. Kết quả chính

| Phiên bản | Câu đơn (400) | Hội thoại[1] (616 slots) | Ngoài scope[1] (80) |
|---|---|---|---|
| **Baseline** | **89,00%** | — | — |
| Texa without retrieval and consistency | 87,50% | 91,40% | 83,75% |
| Texa with only consistency | 87,00% | 92,05% | 93,75% |
| Texa with only retrieval | 90,25% | 96,10% | 86,25% |
| **Texa** | **91,25%** | **94,81%** | **95,00%** |

Baseline nhận schema và định nghĩa nghiệp vụ, kèm tối đa một lần sửa nếu SQL lỗi. Baseline đạt 89,00%, còn Texa đạt 91,25% trên câu đơn. Hội thoại và ngoài phạm vi là các kết quả Texa; chưa đo baseline cho những suite này nên không dùng để so sánh Baseline với Texa.

### 8.2. Hỏi lại khi câu hỏi chưa rõ

| Cấu hình Texa | Hỏi đúng chính sách | Bảng cuối đúng |
|---|---|---|
| Texa without retrieval and consistency | 120/120 (100%) | 119/120 (99,17%) |
| Texa with only consistency | 120/120 (100%) | 120/120 (100%) |
| Texa with only retrieval | 119/120 (99,17%) | 119/120 (99,17%) |
| **Texa** | **120/120 (100%)** | **120/120 (100%)** |

Bảng hỏi lại chỉ so sánh các cấu hình Texa; chưa đo Baseline cho suite này.

### 8.3. Ablation memory và clarification

| Phiên bản | Hội thoại (616) | Clarification table (120) | Clarification policy (120) |
|---|---|---|---|
| Texa with structured memory | 521/616 (84,58%) | — | — |
| Texa with only window-6 memory | 527/616 (85,55%) | — | — |
| Texa without memory | 517/616 (83,93%) | — | — |
| Texa with clarification | — | 104/120 (86,67%) | 90/120 (75,00%) |
| Texa without clarification | — | 75/120 (62,50%) | 60/120 (50,00%) |

Chênh lệch structured memory và window-6 nhỏ trong bộ hiện tại, chưa đủ kết luận cách memory nào luôn tốt hơn. Clarification có tác động rõ hơn. Đây là kết quả exploratory cần holdout độc lập để xác nhận.

### 8.4. Độ khó, lỗi còn lại và vận hành

Theo nhóm độ khó, Baseline/Texa lần lượt đúng 71/80 và 80/80 câu basic; 192/200 và 177/200 câu compositional; 93/120 và 108/120 câu semantic. Baseline nhỉnh hơn ở câu compositional, còn Texa cao hơn ở basic và semantic. Lỗi còn lại gồm từ chối nhầm câu compositional hợp lệ và hiểu sai metric/grain.

Median latency câu đơn: Baseline 6,27 giây, Texa 13,79 giây. Chi phí ước tính cho 400 lượt lần lượt là 0,2076 USD và 0,4014 USD. Latency và chi phí được báo riêng, không cộng vào accuracy. Bộ regression sau phép đo v3 trước đó đạt 398 passed, 36 skipped.

## 9. Thảo luận và giới hạn

### 9.1. Texa giải quyết được gì

1. Catalog làm rõ metric/source/grain mà schema không thể hiện đầy đủ.
2. QuerySpec và compiler tách hiểu ngôn ngữ khỏi tạo SQL, giúp dễ kiểm tra.
3. Clarification và memory có cấu trúc phù hợp hơn việc chỉ kéo dài cửa sổ hội thoại khi câu hỏi tham chiếu kết quả trước.

### 9.2. Điều chưa thể kết luận

> Dataset tổng hợp, domain hẹp, fixture có family liên quan giữa dev/test, chưa có human-reviewed sealed holdout và hai repeat không phải các câu độc lập. Chưa thể kết luận Texa tổng quát cho database doanh nghiệp khác, chưa thể quy chênh lệch hoàn toàn cho retrieval/consistency, và chưa thể dùng accuracy hiện tại làm cam kết production.

### 9.3. Trade-off

So với Baseline, Texa chậm hơn và tốn chi phí cao hơn do có thêm bước phân giải ý nghĩa và kiểm tra truy vấn. Đổi lại, Texa cho biết metric, nguồn, kỳ và bộ lọc dùng để trả lời, đồng thời có thể hỏi lại khi yêu cầu chưa đủ rõ.

## 10. Kết luận và hướng phát triển

Trên bộ câu đơn research-v3, Texa đạt 91,25%, cao hơn Baseline 2,25 điểm phần trăm. Khi được cung cấp cùng định nghĩa nghiệp vụ và một lần sửa SQL lỗi, LLM đạt kết quả gần với Texa; lợi ích còn lại của Texa nằm ở workflow có cấu trúc và khả năng kiểm soát đầu ra.

Hội thoại, hỏi lại và ngoài phạm vi được đánh giá riêng giữa các cấu hình Texa; chưa đo Baseline cho các suite này nên không thể kết luận Texa hơn Baseline ở các tác vụ đó.

1. Khóa sealed holdout do người độc lập review và bổ sung câu hỏi từ PM/PO thật.
2. Mở rộng coverage trong cùng domain trước khi mở thêm engine/database.
3. Dùng adaptive consistency theo uncertainty và ngân sách latency.
4. Theo dõi catalog version, provenance, acceptance/rejection và correction trong shadow mode.
5. Đo tải nhiều người dùng và kiểm tra isolation của memory theo session.
6. Đánh giá confidence calibration và abstention thay vì chỉ accuracy.
7. Chỉ mở rộng join/multi-source sau khi có semantic contract và benchmark tương ứng.

# Phụ lục: Tái lập và thuật ngữ

Artifacts benchmark nằm tại `data/benchmark/results/research-v3-20261106/`; catalog tại `catalog/product_events.yaml`; verified examples tại `catalog/verified_examples.yaml`. Module chính: `interpret.py`, `memory.py`, `examples.py`, `consistency.py` và `answer.py`. Cần gateway credentials riêng và PostgreSQL fixture để chạy lại; credential không được lưu trong report.

| Thuật ngữ | Ý nghĩa |
|---|---|
| Semantic catalog | Lớp quản trị metric, dimension, event role, mapping, coverage và business vocabulary. |
| QuerySpec | Biểu diễn trung gian có kiểu của metric, source, time range, filter, selection và grain. |
| Business accuracy | Tỷ lệ bảng kết quả khớp gold; không phải tỷ lệ chuỗi SQL giống nhau. |
| Clarification | Câu hỏi lại có chủ đích khi metric, source, kỳ hoặc target chưa đủ rõ. |
| Structured memory | Trạng thái gồm slot ngữ nghĩa và result registry có ID. |
| Ablation | Thử nghiệm tắt/bật một component để đo đóng góp riêng trong cùng protocol. |

# Tài liệu tham khảo


1. Yu, T. et al. (2018). Spider: A Large-Scale Human-Labeled Dataset for Complex and Cross-Domain Semantic Parsing and Text-to-SQL Task. EMNLP. DOI: 10.18653/v1/D18-1425.
2. Wang, B. et al. (2020). RAT-SQL: Relation-Aware Schema Encoding and Linking for Text-to-SQL Parsers. ACL. DOI: 10.18653/v1/2020.acl-main.677.
3. Scholak, T., Schucher, N., Bahdanau, D. (2021). PICARD: Parsing Incrementally for Constrained Auto-Regressive Decoding from Language Models. EMNLP. DOI: 10.18653/v1/2021.emnlp-main.779.
4. Yu, T. et al. (2019). SParC: Cross-Domain Semantic Parsing in Context. ACL. DOI: 10.18653/v1/P19-1443.
5. Yu, T. et al. (2019). CoSQL: A Conversational Text-to-SQL Challenge Towards Cross-Domain Natural Language Interfaces to Databases. EMNLP. DOI: 10.18653/v1/D19-1204.
6. Pourreza, M., Rafiei, D. (2023). DIN-SQL: Decomposed In-Context Learning of Text-to-SQL with Self-Correction. NeurIPS Datasets and Benchmarks. DOI: 10.52202/075280-1577.
7. Gao, D. et al. (2024). Text-to-SQL Empowered by Large Language Models: A Benchmark Evaluation. PVLDB, 17(7). DOI: 10.14778/3641204.3641221.
8. Li, J. et al. (2023). Can LLM Already Serve as A Database Interface? A BIg Bench for Large-Scale Database Grounded Text-to-SQLs. NeurIPS Datasets and Benchmarks. DOI: 10.52202/075280-1835.
9. Lei, Z. et al. (2024). Spider 2.0: Evaluating Language Models on Real-World Enterprise Text-to-SQL Workflows. arXiv:2411.07763.

10. Sun, R. et al. (2023). SQL-PaLM: Improved Large Language Model Adaptation for Text-to-SQL. arXiv:2306.00739.
11. Wang, X. et al. (2023). Self-Consistency Improves Chain of Thought Reasoning in Language Models. ICLR. arXiv:2203.11171.
12. dbt Labs. dbt Semantic Layer Documentation. Vendor architecture reference.
13. Cube. Cube Semantic Layer Documentation. Vendor architecture reference.